**Задача:** формирование обучающей выборки, проектирование валидации. **Итог:** сформирована обучающая, тестовая и валидационная выборки, построен пайплайн валидации.

## Валидация

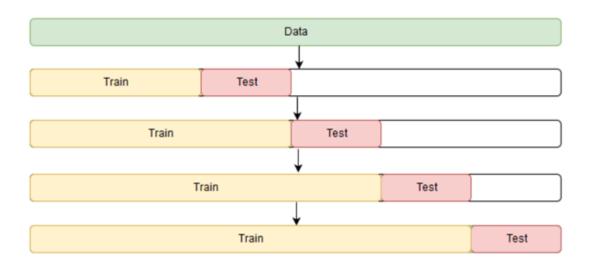
Для отбора кандидатов будут использованы 2 модели:

- → Матричная факторизация.
- → Item2item модель с метрикой близости <u>BM-25</u>. Формула показателя для случая рекомендаций выводилась на Этапе L2;
- → Логистическая матричная факторизация;
- → Bayessian Personalized Ranking.

Прочие модели: <a href="https://github.com/benfred/implicit/blob/main/examples/lastfm.pv#L47">https://github.com/benfred/implicit/blob/main/examples/lastfm.pv#L47</a>.

Базовым алгоритмом решения задачи будет матричная факторизация. Его результат буду пытаться превзойти подходом, реализуемым в 2 этапа: отбор кандидатов и ранжирование.

Данные представляют собой временной ряд, поэтому делать стандартную K-Fold кросс-валидацию нельзя, иначе может потеряться последовательность взаимодействий. Можно зафиксировать временное окно (2 недели) и последовательно сдвигать его. Такой подход называется кросс-валидацией с кумулятивным сплитом, скользящее временное окно. На части train-выборки, которая туда не вошла, считаем значение метрики. Повторяем процедуру, пока не дойдём до конца исследуемого промежутка. Усредняем значение метрики (простое среднее). Полученный результат будет отражать качество модели с конкретным набором параметров.



## Метрики качества

Метрики ошибок отражают, насколько значение прогноза близко к реальному. Применяются к небинарным данным. Это MSE, RMSE, MAE. Численное значение метрик ошибок не несёт смысл о качестве рекомендаций.

В <u>работе</u> метрики, подходящие для оценки качества рекомендательной системы, названы метрика точности классификации модели (classification accuracy metrics). Они применяются в случаях, когда нам не важно прогнозируемое значение само по себе. Это Precision, Recall, ROC-AUC.

## Полезные ссылки:

https://www.jmlr.org/papers/volume12/duchi11a/duchi11a.pdf

https://arxiv.org/ftp/arxiv/papers/1205/1205.2618.pdf

https://github.com/benfred/implicit/blob/main/implicit/bpr.py

https://arxiv.org/ftp/arxiv/papers/1205/1205.2618.pdf

https://github.com/AmazingDD/daisyRec

http://ethen8181.github.io/machine-learning/recsys/4 bpr.htm

https://github.com/shah314/BPR